

LAPORAN PROYEK MACHINE LEARNING

Sistem Klasifikasi Risiko Kehamilan Multi-Dimensi Menggunakan Random Forest



Dosen Pengampu:

Oppir Hutapea, S.Tr.Kom., M.Kom

Disusun oleh:

11423015	:	Samson Nicholas Sitorus
11423016	:	Samuel Margomgom Tua Sitorus
11423037	:	Yosefin Christian Siregar
11423043	:	Jonathan Prima Tamba
11423064	:	Yenny Angelita Gurning

D4-Teknologi Rekayasa Perangkat Lunak

Institut Teknologi Del

2026

Latar Belakang

Pencatatan kesehatan ibu dan anak (KIA) di Indonesia masih berpedoman pada Buku KIA cetak edisi 2024 dari Kementerian Kesehatan RI. Buku ini memuat panduan terpadu mulai kehamilan hingga anak usia enam tahun, termasuk jadwal imunisasi, grafik pertumbuhan, serta daftar tanda bahaya seperti perdarahan dan gerakan janin berkurang yang perlu rujukan segera Berdasarkan Survei Status Gizi Indonesia (SSGI), prevalensi (proporsi/ persentase) anak balita stunting nasional tercatat 19,8% [1]. Stunting terjadi karena ketidakcukupan asupan gizi, infeksi berulang serta faktor sosial ekonomi dan lingkungan yang tidak memadai. Sumatera Utara merupakan salah satu provinsi dengan angka stunting tertinggi di Indonesia berjumlah 22% balita [2].

Posyandu (Pos Pelayanan Terpadu) Sawo terletak di Desa Hutabulu Mejan, Kecamatan Balige, Kabupaten Toba, provinsi Sumatera Utara. Desa ini memiliki luas 1,15 km² dan terdiri dari tiga dusun: Hutabulu, Hutagurgur, dan Mejan. Data Dinas Kesehatan Toba pada November 2024 mencatat prevalensi stunting 7,53% dari 10.176 anak yang diukur, dengan 766 balita stunting [3]. Posyandu Sawo melayani ibu hamil dan balita setiap bulan. Pencatatan masih manual menggunakan map per kartu keluarga, kemudian di-entry ulang bidan desa ke sistem puskesmas, menyebabkan jeda waktu. Jika ibu lupa membawa buku KIA, data dicatat di map sementara yang tidak terintegrasi. Kesadaran orang tua datang ke Posyandu rendah, sehingga kader sering menjemput. Kendala ini berdampak pada kelambatan deteksi risiko tinggi, keterlambatan rujukan, dan potensi luputnya pemantauan gizi anak.

Berbagai aplikasi digital KIA seperti e-KIA, aplikasi Android untuk desa Pedindang, dan GKIA telah dikembangkan. Namun, mayoritas hanya pengganti catatan manual tanpa analisis otomatis tanda bahaya. Kader non-IT masih harus menginterpretasi manual kriteria risiko Buku KIA, sementara internet di pedesaan tidak stabil. Hal ini menyebabkan pemanfaatan aplikasi yang ada belum optimal dalam mendukung pengambilan keputusan di tingkat Posyandu.

Di sisi lain, penerapan kecerdasan buatan (*Artificial Intelligence*) dalam kesehatan ibu dan anak di Indonesia telah menunjukkan hasil menjanjikan. Amnur, Rahmayuni, dan Aldi [4] mengembangkan sistem pakar skrining kehamilan risiko tinggi menggunakan metode Forward Chaining yang mampu mendeteksi tingkat risiko secara dini. Sejalan dengan hal tersebut, Syaputra, Yuhandri dan Sumijan [5] menghasilkan sistem pakar deteksi dini stunting dengan

metode serupa untuk mengidentifikasi kelompok sasaran yang berisiko. Namun, sistem-sistem tersebut umumnya masih berbasis aturan statis (rule-based), sehingga diperlukan pendekatan yang lebih dinamis melalui Machine Learning untuk memprediksi risiko komplikasi kehamilan yang lebih kompleks berdasarkan akumulasi data klinis, serta mengintegrasikannya dengan kriteria Buku KIA 2024 melalui antarmuka yang ramah bagi kader Posyandu.

Kegiatan ini akan mengembangkan dashboard digital terintegrasi untuk monitoring KIA di Posyandu Sawo bersama mitra (kader dan bidan desa). Sistem ini menggabungkan formulir digital Buku KIA dengan teknologi Machine Learning (seperti Random Forest atau Logistic Regression) untuk memprediksi risiko preeklamsia dengan menganalisis pola kombinasi faktor risiko dari data akumulasi Antenatal Care (ANC). Selain kemampuan prediksi tersebut, dashboard juga menghitung status gizi (BB/U, PB/U, LiLA) sesuai Permenkes No. 2 Tahun 2020, memberikan peringatan warna (merah, kuning, hijau), serta menyajikan grafik tren pertumbuhan secara otomatis. Dirancang dengan antarmuka intuitif (ikon besar dan alur sederhana), sistem ini ditujukan agar mudah dioperasikan oleh kader dengan latar belakang pendidikan minimal SMP. Harapannya, proses pencatatan menjadi lebih cepat dan akurat, menghasilkan data terpusat sebagai pendukung keputusan kesehatan di Desa Hutabulu Mejan, serta menjadi model best practice yang dapat direplikasi di Posyandu lain.

Tujuan Penerapan Machine Learning

Penerapan Machine Learning pada aplikasi Generasi Sehat bertujuan untuk membantu tenaga kesehatan, khususnya bidan dan dokter, dalam melakukan deteksi dini terhadap risiko kesehatan ibu hamil berdasarkan data pemeriksaan kesehatan yang tersedia pada sistem. Teknologi ini digunakan untuk mendukung proses analisis data kesehatan secara otomatis sehingga pelayanan kesehatan dapat dilakukan dengan lebih cepat, tepat, dan terarah.

Pada penelitian dan pengembangan aplikasi Generasi Sehat, data yang digunakan berasal dari Desa Hutabulu Mejan berupa data pemeriksaan Antenatal Care (ANC) ibu hamil. Dataset tersebut mencakup berbagai informasi kesehatan, seperti usia kehamilan, tekanan darah, tinggi fundus uteri, hemoglobin, indeks massa tubuh (IMT), lingkaran lengan atas (LiLA), riwayat penyakit, hasil skrining Tripel Eliminasi, serta hasil pemeriksaan kesehatan lainnya.

Tujuan utama penerapan Machine Learning pada aplikasi ini meliputi:

1. Memprediksi tingkat risiko kehamilan secara objektif berdasarkan data pemeriksaan ANC.
2. Mengidentifikasi jenis risiko kehamilan secara spesifik dan simultan, sehingga rincian risiko yang dialami ibu hamil dapat diketahui secara otomatis tanpa analisis manual penuh oleh tenaga kesehatan.
3. Membantu tenaga kesehatan dalam pengambilan keputusan melalui informasi risiko yang konsisten antara status keseluruhan dan jenis risiko yang terdeteksi.
4. Mencapai akurasi model minimal 80% untuk prediksi risiko keseluruhan.

Melalui penerapan Machine Learning, sistem Generasi Sehat diharapkan mampu membantu mengidentifikasi enam jenis risiko spesifik, yaitu risiko kematian ibu, risiko keguguran/prematur, risiko preeklampsia/hipertensi, risiko anemia berat, risiko BBLR/stunting pada bayi, serta risiko infeksi menular (Tripel Eliminasi). Sistem akan menganalisis data pemeriksaan kesehatan secara otomatis untuk menghasilkan informasi risiko, alasan klinis, dan notifikasi kepada bidan sebagai bahan pendukung dalam pengambilan keputusan pelayanan kesehatan.

Target Label Klasifikasi

Sistem Machine Learning pada KIA Cerdas mengklasifikasikan risiko kehamilan ke dalam tiga kategori risiko keseluruhan (overall) sebagaimana ditunjukkan pada Tabel 1. Berbeda dari rancangan sebelumnya, label risiko keseluruhan pada rancangan ini tidak lagi ditentukan oleh fungsi scoring independen, melainkan diturunkan secara langsung dan konsisten dari hasil deteksi enam jenis risiko spesifik, sehingga tidak terdapat kontradiksi antara status keseluruhan dan rincian jenis risiko yang ditampilkan kepada bidan.

Tabel 1. Target Label Klasifikasi

Kategori (Label Keseluruhan)	Kondisi Trigger	Tindakan
NORMAL (Risiko Rendah)	Tidak ada satu pun dari enam jenis risiko spesifik yang terdeteksi.	Pemantauan rutin oleh kader/bidan, tidak memerlukan tindakan khusus.

Kategori (Label Keseluruhan)	Kondisi Trigger	Tindakan
PERLU TINDAKAN (Risiko Sedang)	Hanya Risiko BBLR/Stunting Bayi yang terdeteksi, tanpa disertai satu pun dari lima risiko berat lainnya.	Memerlukan perhatian, intervensi gizi, pengobatan dasar, atau tindakan lanjutan dari bidan di Puskesmas/Posyandu.
PERLU RUJUKAN (Risiko Tinggi)	Terdeteksi minimal satu dari lima risiko berat: Risiko Kematian Ibu, Risiko Keguguran/Prematur, Risiko Preeklampsia/Hipertensi, Risiko Anemia Berat, atau Risiko Infeksi Menular.	Kondisi kritis atau komorbiditas berat yang mengancam nyawa ibu/janin, memerlukan rujukan segera ke Rumah Sakit (Faskes lebih tinggi).

Keenam jenis risiko spesifik yang menjadi dasar penentuan label keseluruhan tersebut, beserta cakupan kondisi klinisnya, dijelaskan pada Tabel 2 berikut.

Tabel 2. Cakupan Enam Jenis Risiko Spesifik

Jenis Risiko Spesifik	Cakupan Kondisi Klinis
Risiko Kematian Ibu	Tekanan darah $\geq 160/110$ mmHg, Hb $< 8,0$ g/dL, riwayat penyakit jantung (decompensated heart failure), komorbiditas berat (TB aktif + anemia, atau HIV Reaktif + anemia), serta riwayat abortus ≥ 3 kali.
Risiko Keguguran/Prematur	Riwayat abortus ≥ 2 kali, grandmultipara dengan usia kehamilan < 32 minggu, Hb $< 9,0$ g/dL, riwayat diabetes melitus, serta usia ibu yang masih remaja.
Risiko Preeklampsia/Hipertensi	Tekanan darah $\geq 140/90$ mmHg, Mean Arterial Pressure (MAP) > 107 , riwayat hipertensi, serta kombinasi obesitas dengan prehipertensi.

Risiko Anemia Berat	Hb < 8,0 g/dL; Hb < 9,5 g/dL disertai KEK; Hb < 10,0 g/dL disertai status gizi kurus; atau Hb < 11,0 g/dL disertai riwayat anemia.
Risiko BBLR/Stunting Bayi	Kurang Energi Kronis/KEK (LiLA < 23,5 cm), IMT < 18,5, Hb < 10 g/dL dengan kondisi mendekati ambang KEK, atau usia ibu < 19 tahun.
Risiko Infeksi Menular (Tripel Eliminasi)	Hasil skrining HIV Reaktif, Sifilis Reaktif, Hepatitis B Reaktif, atau riwayat Hepatitis B yang memerlukan terapi ARV, terapi Sifilis, atau persiapan HBIG untuk bayi.

Dataset dan Sumber Data

Dataset yang digunakan pada penerapan Machine Learning di aplikasi Generasi Sehat berasal dari data pemeriksaan Antenatal Care (ANC) ibu hamil di Desa Hutabulu Mejan. Dataset ini merupakan dataset primer yang diambil langsung dari rekam medis ANC. Data tersebut diperoleh dari hasil pencatatan pelayanan kesehatan ibu hamil yang dilakukan oleh bidan desa dan tenaga kesehatan setempat. Rincian karakteristik dataset hasil pembaruan dapat dilihat pada Tabel 3 berikut.

Tabel 3. Karakteristik Dataset

Karakteristik	Keterangan
Jumlah Baris (Pasien)	10.000 pasien
Jumlah Kolom (Fitur)	38 kolom
Sumber Data	Rekam medis ANC primer, Desa Hutabulu Mejan
Jenis Dataset	Dataset primer
Pembagian Data	Train 8.000 (80%) Test 2.000 (20%), stratifikasi berdasarkan label risiko keseluruhan

Dataset ini mencakup berbagai variabel medis dan personal yang krusial untuk menentukan faktor risiko pada ibu hamil. Pengelompokan seluruh fitur yang digunakan ke dalam beberapa kategori utama dapat dilihat pada Tabel 4 berikut:

Tabel 4. Kolom Utama Dataset

Nama Kolom	Deskripsi
Tgl Lahir	Tanggal lahir ibu hamil untuk menghitung usia ibu.
Tgl HPHT	Hari Pertama Haid Terakhir sebagai acuan awal kehamilan.
Tgl HPL	Perkiraan Hari Persalinan (Estimated Due Date).
Usia Kehamilan (minggu)	Lama kehamilan yang dihitung dalam minggu sejak HPHT.
Trimester	Pembagian usia kehamilan (Trimester 1, 2, atau 3).
Gravida	Jumlah total kehamilan yang pernah dialami ibu.
Para	Jumlah persalinan yang berhasil mencapai usia kehamilan viable.
Abortus	Jumlah keguguran atau kehamilan yang tidak berhasil.
Berat Badan Sebelum Hamil (kg)	Berat badan ibu sebelum kehamilan dimulai.
Tinggi Badan (cm)	Tinggi badan ibu untuk perhitungan IMT.
IMT	Indeks Massa Tubuh ibu sebelum hamil.
Kategori IMT	Klasifikasi IMT (kurus, normal, overweight, obesitas).
LiLA (cm)	Lingkar Lengan Atas sebagai indikator status gizi ibu.
Kategori LiLA	Klasifikasi status gizi berdasarkan LiLA.
Tekanan Darah (mmHg)	Hasil pengukuran tekanan darah ibu.
TD Sistolik	Nilai tekanan darah sistolik.

Nama Kolom	Deskripsi
TD Diastolik	Nilai tekanan darah diastolik.
Kategori TD	Klasifikasi tekanan darah (normal, prehipertensi, hipertensi).
Tinggi Fundus Uteri (cm)	Pengukuran tinggi rahim untuk memantau perkembangan janin.
Hemoglobin/Hb (g/dL)	Kadar hemoglobin dalam darah ibu.
Kategori Hb	Klasifikasi anemia atau normal berdasarkan Hb.
Golongan Darah	Golongan darah ibu (A, B, AB, O).
Status Imunisasi TD	Status imunisasi Tetanus Diphtheria (lengkap/belum).
Tripel Eliminasi - HIV	Hasil skrining HIV pada ibu hamil.
Tripel Eliminasi - Sifilis	Hasil skrining sifilis.
Tripel Eliminasi - Hep B	Hasil skrining Hepatitis B.

Analisis Kebutuhan Data

Analisis kebutuhan data dilakukan untuk menentukan jenis data yang diperlukan dalam proses penerapan Machine Learning pada aplikasi Generasi Sehat. Data yang digunakan berasal dari hasil pemeriksaan ibu hamil di Desa Hutabulu Mejan yang dicatat oleh bidan pada layanan Antenatal Care (ANC).

Beberapa kebutuhan data yang digunakan pada sistem Generasi Sehat meliputi:

1. Data Identitas Ibu Hamil, digunakan untuk mengidentifikasi pasien yang melakukan pemeriksaan, seperti nama ibu, usia, alamat, nomor pemeriksaan, dan usia kehamilan.
2. Data Pemeriksaan Fisik, digunakan untuk mengetahui kondisi kesehatan ibu hamil, meliputi tekanan darah sistolik dan diastolik, berat badan, tinggi badan, indeks massa tubuh (IMT), lingkaran lengan atas (LiLA), dan tinggi fundus uteri (TFU).

3. Data Pemeriksaan Laboratorium, digunakan untuk mendukung identifikasi risiko kesehatan ibu hamil, seperti kadar hemoglobin (Hb) dan hasil skrining Tripel Eliminasi (HIV, Sifilis, Hepatitis B).
4. Data Riwayat Kesehatan, digunakan untuk mengetahui riwayat kesehatan ibu yang dapat memengaruhi kondisi kehamilan, seperti riwayat hipertensi, riwayat diabetes, riwayat penyakit jantung, riwayat komplikasi kehamilan, dan riwayat persalinan sebelumnya (gravida, para, abortus).
5. Data Hasil Pemeriksaan Kehamilan, mencakup hasil pemeriksaan rutin kehamilan yang dilakukan oleh bidan, seperti jumlah kunjungan ANC, kondisi janin, serta kondisi kesehatan ibu secara umum.

Seluruh data tersebut digunakan sebagai bahan analisis dalam proses Machine Learning untuk menghasilkan informasi risiko keseluruhan dan enam jenis risiko spesifik secara otomatis. Data yang telah dikumpulkan kemudian melalui proses preprocessing dan feature engineering sebelum digunakan dalam pelatihan dan pengujian model Machine Learning pada aplikasi KIA Cerdas.

Tahapan Machine Learning

Tahapan *Machine Learning* pada aplikasi Generasi Sehat dilakukan secara bertahap untuk menghasilkan sistem deteksi dini risiko kesehatan ibu hamil yang mampu memberikan informasi dan notifikasi risiko secara otomatis kepada bidan.

Tahapan *Machine Learning* pada aplikasi Generasi Sehat terdiri dari beberapa proses utama, yaitu sebagai berikut:

1. Pengumpulan Data (*Data Collection*)

Tahap pertama dilakukan dengan mengumpulkan data pemeriksaan kesehatan ibu hamil yang berasal dari Desa Hutabulu Mejan. Data tersebut diperoleh dari hasil pelayanan *Antenatal Care* (ANC) yang dilakukan oleh bidan desa dan tenaga kesehatan. Data yang dikumpulkan meliputi data identitas pasien, pemeriksaan fisik, hasil laboratorium, riwayat kesehatan, dan hasil pemeriksaan kehamilan lainnya. Data yang telah dikumpulkan kemudian digunakan sebagai sumber utama dalam proses pengembangan model *Machine Learning* pada aplikasi Generasi Sehat.

2. Preprocessing Data

Setelah proses pengumpulan data selesai, tahap selanjutnya adalah *preprocessing data*. Tahap ini bertujuan untuk membersihkan dan mempersiapkan data agar dapat digunakan dalam proses pelatihan model Machine Learning. Beberapa proses yang dilakukan meliputi:

1. Penanganan Data Hilang (Missing Value Handling)

Proses ini dilakukan untuk mengidentifikasi dan menangani nilai kosong (*Null* atau *NaN*) pada dataset agar tidak menyebabkan galat (*error*) saat proses *training*.

Langkah-langkah penanganannya diimplementasikan sebagai berikut:

- a. Konversi Format Tanggal: Mengonversi kolom Tgl Lahir menjadi format *datetime* menggunakan fungsi `pd.to_datetime()` dengan parameter `errors='coerce'` untuk memastikan data tanggal yang tidak valid diubah menjadi *NaN* agar dapat diproses secara seragam.

```
df['Tgl Lahir'] = pd.to_datetime(df['Tgl Lahir'], dayfirst=True, errors='coerce')
```

- b. Transformasi Fitur Usia Ibu: Menghitung karakteristik *Usia_Ibu* secara matematis berdasarkan selisih tanggal acuan (2025-10-01) dengan data Tgl Lahir. Jika nilai dasar kosong, sistem menetapkan nilai *default* 28, kemudian dilakukan pembatasan rentang (*clipping*) fitur pada batas aman minimal 14 tahun dan maksimal 55 tahun.

```
df['Usia_Ibu'] = df['Tgl Lahir'].apply(  
    lambda x: (pd.Timestamp('2025-10-01') - x).days // 365 if pd.notnull(x) else 28  
).clip(14, 55)
```

- c. Imputasi Spesifik Berbasis Grup: Menangani data kosong pada fitur numerik medis Tinggi Fundus Uteri (cm) menggunakan teknik Imputasi Median yang dikelompokkan secara spesifik per kelompok Trimester kehamilan (`df.groupby('Trimester').transform()`) guna menjaga relevansi data medis.

```
df['Tinggi Fundus Uteri (cm)'] = df.groupby('Trimester')['Tinggi Fundus Uteri (cm)'].transform(  
    lambda x: x.fillna(x.median()))
```

- d. Imputasi Fitur Kategorikal: Mengisi nilai kosong pada kolom target tindakan medis Tindakan secara langsung dengan nilai kategori dominan (konstan), yaitu 'Normal' melalui fungsi `.fillna('Normal')`.

```
df['Tindakan'] = df['Tindakan'].fillna('Normal')
```

2. Penanganan Noise dan Data Ekstrem (Noise and Outlier Handling)

Data ekstrem atau pencilan (outlier) terdeteksi pada sejumlah fitur numerik penting, seperti Usia_Ibu, Usia Kehamilan (minggu), Gravida, Para, Abortus, IMT, LiLA (cm), Tinggi Fundus Uteri (cm), TD Sistolik, TD Diastolik, Hemoglobin/Hb (g/dL), dan Kunjungan ANC Ke-. Untuk mencegah distorsi pada performa model akibat pencilan ini, diterapkan algoritma penanganan berikut:

- Deteksi Metode IQR (Interquartile Range): Menghitung nilai Kuartil 1 (Q1 atau persentil 25) dan Kuartil 3 (Q3 atau persentil 75) dari setiap fitur numerik untuk menetapkan ambang batas bawah ($\text{lower_bound} = Q1 - 1.5 \times \text{IQR}$) serta ambang batas atas ($\text{upper_bound} = Q3 + 1.5 \times \text{IQR}$).
- Strategi Capping (Winsorizing): Alih-alih menghapus data pencilan yang berisiko membuang informasi penting, nilai ekstrem yang berada di luar batas kewajaran disesuaikan secara otomatis menggunakan fungsi `.clip(lower_bound, upper_bound)`.

```
# 2 Penanganan Noise dan Outlier
print("\n [2.2] Penanganan Noise dan Outlier:")

# Deteksi outlier menggunakan IQR untuk fitur numerik
numeric_cols = ['Usia_Ibu', 'Usia Kehamilan (minggu)', 'Gravida', 'Para', 'Abortus',
                'IMT', 'LiLA (cm)', 'Tinggi Fundus Uteri (cm)', 'TD Sistolik',
                'TD Diastolik', 'Hemoglobin/Hb (g/dL)', 'Kunjungan ANC Ke-']

outlier_summary = {}
for col in numeric_cols:
    if col in df.columns:
        Q1 = df[col].quantile(0.25)
        Q3 = df[col].quantile(0.75)
        IQR = Q3 - Q1
        lower_bound = Q1 - 1.5 * IQR
        upper_bound = Q3 + 1.5 * IQR
        outliers = df[(df[col] < lower_bound) | (df[col] > upper_bound)]
        outlier_summary[col] = len(outliers)
        if len(outliers) > 0:
            # Capping outliers (winsorizing)
            df[col] = df[col].clip(lower_bound, upper_bound)
            print(f"    {col}: {len(outliers)} outlier ditangani dengan capping")

...

[2.2] Penanganan Noise dan Outlier:
Abortus: 1998 outlier ditangani dengan capping
TD Sistolik: 148 outlier ditangani dengan capping
TD Diastolik: 197 outlier ditangani dengan capping
```

Proses eksekusi dan ringkasan deteksi pencilan yang berhasil ditangani dengan metode capping ini dapat dilihat pada Gambar 3 berikut, yang mencakup penyesuaian otomatis pada fitur-fitur berikut:

- a. Fitur Abortus: Sebanyak 1.998 data pencilan berhasil dilakukan capping.
- b. Fitur TD Sistolik: Sebanyak 148 data pencilan berhasil dilakukan capping.
- c. Fitur TD Diastolik: Sebanyak 197 data pencilan berhasil dilakukan capping.

3. Penanganan Ketidakseimbangan Kelas (Handling Imbalance)

Sebelum dilakukan penanganan ketidakseimbangan, distribusi awal data pada kelas risiko menunjukkan dominasi yang tidak seimbang (imbalanced), dengan rincian pada gambar 3.55 berikut.

Distribusi kelas risiko (sebelum handling imbalance):

PERLU TINDAKAN	: 4,002 (40.0%)
NORMAL	: 3,432 (34.3%)
PERLU RUJUKAN	: 2,566 (25.7%)

```
[5.2] Split Data: Train 8,000 | Test 2,000
```

```
[5.3] Penanganan Data Imbalance (Oversampling):
```

```
Kelas terbanyak: 3202 sampel
```

```
Kelas 0: oversample dari 3202 ke 3202
```

```
Kelas 2: oversample dari 3202 ke 3202
```

```
Distribusi setelah oversampling: {2: np.int64(3202), 1: np.int64(3202), 0: np.int64(3202)}
```

Kondisi ketidakseimbangan kelas ini dapat memicu bias prediksi model yang condong pada kelas mayoritas. Penanganan masalah ini dirancang melalui tahapan terstruktur:

- a. Pemisahan Dataset (Data Splitting): Untuk menghindari terjadinya kebocoran data (data leakage), dataset dipisahkan terlebih dahulu ke dalam proporsi Data Train: 8.000 sampel dan Data Test: 2.000 sampel.
- b. Metode Oversampling (Random Resampling): Proses penyeimbangan kelas hanya diaplikasikan pada porsi Data Train. Sistem mendeteksi jumlah sampel dari kelas terbanyak setelah proses splitting (yaitu 3.202 sampel) sebagai performa acuan target. Selanjutnya, sampel pada Kelas 0 dan Kelas 2 direplikasi secara acak (oversample) hingga masing-masing memiliki volume data yang setara.

- c. Hasil Akhir Distribusi: Hasil akhir setelah penerapan teknik oversampling menunjukkan distribusi kelas target yang sepenuhnya seimbang, di mana masing-masing kelas (Kelas 0, Kelas 1, dan Kelas 2) tepat memiliki ukuran 3.202 sampel.

3. Feature Engineering

Proses feature engineering menghasilkan 41 fitur klinis terstruktur yang dikelompokkan ke dalam delapan kategori klinis berdasarkan panduan Kemenkes RI dan Buku KIA 2023, sebagaimana disajikan pada Tabel 5 berikut.

Tabel 5. Seleksi Fitur

Kelompok Fitur	Fitur	Jumlah
Data Dasar Obstetrik	Usia_Ibu, UK (minggu), Trimester_Num, Gravida, Para, Abortus, Kunjungan ANC Ke-	7
Antropometri	IMT, LiLA (cm), Tinggi Fundus Uteri (cm)	3
Tanda Vital	TD Sistolik, TD Diastolik, MAP, Pulse Pressure	4
Laboratorium	Hemoglobin/Hb (g/dL)	1
Riwayat & Tripel Eliminasi	Riwayat_Enc, Riwayat_Berat, Riwayat_Metabolik, HIV_Rek, Sif_Rek, HepB_Rek, Tripel_Total	7
Kategori Encoded	KatIMT_Enc, KatLiLA_Enc, KatTD_Enc, KatHb_Enc, Imunisasi_Enc	5
Binary Clinical Flags	Anemia_Flag, Anemia_Berat, Hiper_Flag, Hiper_Berat, MAP_Tinggi, KEK_Flag, IMT_Kurus, IMT_Obese, Usia_Risiko, Abortus_Tinggi, Grandemulti, Primigravida, ANC_Terlambat	13
Skor Komposit	Risk_Score (agregasi 0–30+)	1

Beberapa formula fitur turunan utama yang digunakan ditunjukkan pada Tabel 6 berikut.

Tabel 6. Formula Fitur Turunan Utama

Feature Baru	Formula / Keterangan
MAP (Mean Arterial Pressure)	$(TD \text{ Sistolik} + 2 \times TD \text{ Diastolik}) / 3$
Pulse Pressure	$TD \text{ Sistolik} - TD \text{ Diastolik}$
Trimester_Num	Trimester I→1, II→2, III→3
Tripel_Total	HIV + Sifilis + Hepatitis B (total reaktif)
Risk_Score	Agregasi 10+ indikator risiko klinis
Anemia_Flag / Anemia_Berat	1 jika Hemoglobin/Hb < 11,0 g/dL / < 8,0 g/dL
Hiper_Flag / Hiper_Berat	1 jika TD Sistolik ≥ 140 mmHg / ≥ 160 mmHg
KEK_Flag	1 jika LiLA < 23,5 cm
Usia_Risiko	1 jika usia < 19 atau > 38 tahun

Encoding dan Scaling: fitur kategorikal dikonversi menjadi nilai numerik (KatIMT_Enc, KatLiLA_Enc, KatTD_Enc, KatHb_Enc, Imunisasi_Enc, Riwayat_Enc), sedangkan fitur numerik dinormalisasi menggunakan StandardScaler (mean = 0, std = 1) yang di-fit pada data training.

Pemilihan Algoritma dan Arsitektur Model

Dipilih dua model *Machine Learning* yang saling melengkapi untuk melakukan prediksi risiko kehamilan. Pendekatan yang digunakan adalah Multi-Output Classification, di mana risiko keseluruhan dan enam jenis risiko spesifik diprediksi menggunakan model yang berbeda namun tetap konsisten secara logis.

Tabel 7. Pemilihan Algoritma dan Arsitektur Model

Model	Fungsi	Karakteristik Utama
Random Forest (Overall)	Memprediksi label risiko keseluruhan (3 kelas: NORMAL, PERLU TINDAKAN, PERLU RUJUKAN)	Menggunakan metode <i>ensemble learning</i> (bagging), robust terhadap outlier, mampu menangani hubungan non-linear, serta menyediakan informasi <i>feature importance</i>
MultiOutputClassifier (6 Jenis Risiko)	Memprediksi enam jenis risiko spesifik secara simultan, dengan setiap risiko dimodelkan menggunakan estimator Random Forest independen	Setiap jenis risiko memiliki distribusi dan faktor penentu yang berbeda sehingga dimodelkan secara independen

Model Random Forest Overall

Model pertama digunakan untuk memprediksi tiga kelas risiko keseluruhan. Untuk mengatasi ketidakseimbangan kelas, dilakukan proses oversampling pada data pelatihan, khususnya pada kelas PERLU TINDAKAN.

Alur proses Random Forest Overall adalah sebagai berikut:

- Dataset pelatihan terdiri atas 8.000 data dan meningkat menjadi 15.204 sampel setelah proses oversampling.
- Data dilakukan proses penskalaan menggunakan StandardScaler.
- Model Random Forest dilatih menggunakan parameter yang telah dioptimalkan.
- Hasil prediksi diperoleh melalui mekanisme majority voting untuk menentukan label risiko keseluruhan.
- Implementasi model menggunakan RandomForestClassifier(n_estimators=200, max_depth=20, min_samples_split=2, max_features='sqrt', class_weight='balanced', random_state=42).

Model MultiOutputClassifier

Model kedua menggunakan MultiOutputClassifier dari scikit-learn, di mana setiap jenis risiko dimodelkan menggunakan Random Forest independen sebagai base estimator.

- Fitur masukan (X) terdiri atas 41 fitur klinis hasil feature engineering.
- Base estimator yang digunakan adalah RandomForestClassifier(n_estimators=150, max_depth=15, class_weight='balanced', random_state=42).
- Implementasi model dilakukan menggunakan MultiOutputClassifier(base_rf, n_jobs=1).fit(X_train_types_scaled, y_train_types).
- Keluaran model berupa probabilitas dan label biner (terdeteksi/tidak terdeteksi) untuk masing-masing dari enam jenis risiko spesifik.

Hyperparameter Tuning

Tuning hyperparameter pada model Random Forest Overall dilakukan untuk memperoleh kombinasi parameter terbaik yang menyeimbangkan akurasi prediksi dan generalisasi model terhadap data baru, sebagaimana disajikan pada Tabel 8 berikut.

Tabel 8. Hyperparameter Model Random Forest Overall

Parameter	Nilai	Keterangan
n_estimators	200	Jumlah pohon dalam hutan
max_depth	20	Kedalaman maksimum pohon
min_samples_split	2	Minimum sampel untuk split
max_features	sqrt	Fitur yang dipertimbangkan per split
class_weight	balanced	Kompensasi ketidakseimbangan kelas
random_state	42	Reproducibility
Train/Test Split	80% / 20%	8.000 train, 2.000 test, stratify=y_overall
Oversampling	resample (sklearn)	Menyeimbangkan kelas PERLU TINDAKAN

Feature Importance

Berdasarkan hasil analisis model Random Forest Overall terhadap 41 fitur, tingkat kepentingan fitur (feature importance) yang paling berpengaruh terhadap prediksi risiko kehamilan secara keseluruhan dapat dilihat pada Tabel 9 berikut.

Tabel 9. Feature Importance Tertinggi

Peringkat	Feature	Importance Score
1	Risk_Score (agregasi indikator risiko)	0,228
2	Riwayat_Berat (riwayat penyakit berat)	0,184
3	Riwayat_Enc (encoding riwayat penyakit)	0,071

Selain feature importance untuk model overall, performa Model MultiOutputClassifier juga dievaluasi per jenis risiko, sebagaimana disajikan pada Tabel 10 berikut.

Tabel 10. Performa Model MultiOutputClassifier per Jenis Risiko Spesifik

Jenis Risiko	Kriteria Utama (Klinis)	Accuracy	F1-Score
Risiko Kematian Ibu	$TD \geq 160/110$, $Hb < 8,0$, riwayat jantung, TB+anemia, abortus ≥ 3	95,1%	0,739
Risiko Keguguran/Prematur	Abortus ≥ 2 , grandmultipara UK<32, $Hb < 9,0$, DM, ibu remaja	96,7%	0,947
Risiko Preeklampsia/Hipertensi	$TD \geq 140/90$, MAP > 107, riwayat hipertensi, obesitas+pre-HTN	93,3%	0,899
Risiko Anemia Berat	$Hb < 8,0$; $Hb < 9,5$ +KEK; $Hb < 10,0$ +kurus; $Hb < 11$ +riwayat	97,3%	0,862
Risiko BBLR/Stunting	KEK (LiLA<23,5), IMT<18,5, $Hb < 10$ +border KEK, ibu<19 thn	98,8%	0,983
Risiko Infeksi Menular	HIV/Sifilis/HepB Reaktif, riwayat HepB	95,7%	0,869

Secara keseluruhan, Hamming Loss model MultiOutputClassifier adalah 0,0387, yang berarti rata-rata hanya 3,87% dari label jenis risiko yang diprediksi salah per sampel, sebuah nilai yang sangat baik untuk kasus multi-label dengan enam output.

Rancangan Evaluasi dan Hasil Model

Evaluasi dilakukan secara komprehensif menggunakan berbagai metrik untuk menilai performa kedua model dalam mengklasifikasikan risiko kehamilan.

Metrik Evaluasi yang Digunakan:

1. Output Risiko Keseluruhan (Multi-class): akurasi total (target > 0,80), confusion matrix, classification report (precision, recall, F1 per kelas), serta ROC AUC (one-vs-rest) jika diperlukan.
2. Output Jenis Risiko (Multi-label/Multi-output): Hamming Loss sebagai proporsi label yang salah diprediksi, serta accuracy dan F1-score per jenis risiko untuk menilai ketepatan tiap deteksi risiko spesifik.

Hasil Akhir Model Random Forest Overall: model terbaik yang dipilih untuk klasifikasi risiko keseluruhan adalah Random Forest dengan accuracy 95,55%, melampaui target minimal 80% yang ditetapkan. Rincian hasil evaluasi per kelas dapat dilihat pada Tabel 11 berikut.

Tabel 11. Hasil Akhir Model Random Forest Overall

Kelas	Precision	Recall	F1-Score
NORMAL (Risiko Rendah)	0,96	0,94	0,95
PERLU TINDAKAN (Risiko Sedang)	0,93	0,88	0,90
PERLU RUJUKAN (Risiko Tinggi)	0,96	0,97	0,96

Output Sistem Machine Learning

Tahap akhir adalah penyajian hasil prediksi kepada pengguna sistem. Berbeda dari rancangan sebelumnya yang hanya menampilkan label risiko keseluruhan, hasil revisi menampilkan rincian prediksi yang lebih lengkap pada dashboard aplikasi KIA Cerdas. Sistem memberikan:

1. Kategori risiko keseluruhan: Normal / Perlu Tindakan / Perlu Rujukan, ditampilkan dalam bentuk indikator berwarna (hijau/kuning/merah).

2. Rincian enam jenis risiko spesifik beserta probabilitas deteksi masing-masing (Risiko Kematian Ibu, Keguguran/Prematur, Preeklampsia/Hipertensi, Anemia Berat, BBLR/Stunting, dan Infeksi Menular).
3. Alasan klinis spesifik yang diturunkan langsung dari nilai input pemeriksaan pasien, misalnya keterangan tekanan darah, kadar Hb, atau hasil LiLA yang menjadi dasar deteksi risiko.
4. Notifikasi atau peringatan kepada bidan jika terdeteksi risiko tinggi pada salah satu jenis risiko.
5. Rekomendasi tindak lanjut medis yang sesuai dengan jenis risiko yang terdeteksi.
6. Informasi pemeriksaan lanjutan kepada bidan sebagai bahan pengambilan keputusan.

Dengan rincian output yang lebih terstruktur tersebut, peran tenaga kesehatan dalam alur kerja bergeser dari menentukan jenis risiko secara manual menjadi memvalidasi dan menentukan tindak lanjut atas breakdown risiko yang telah disediakan oleh sistem, sehingga nilai tambah aplikasi KIA Cerdas sebagai Decision Support System menjadi lebih substansial.

Kesimpulan dan Insight

Penerapan Machine Learning pada aplikasi Generasi Sehat menggunakan pendekatan *Multi-Output Classification* berbasis Random Forest dan *rule-based* klinis maternal, sehingga menghasilkan model klasifikasi risiko kehamilan yang lebih informatif dan terstruktur. Beberapa *insight* utama yang diperoleh adalah sebagai berikut:

1. Sistem mampu mengidentifikasi enam jenis risiko spesifik secara simultan, tidak hanya menghasilkan label risiko keseluruhan, dengan nilai Hamming Loss yang sangat rendah, yaitu sebesar 0,0387.
2. Label risiko keseluruhan diturunkan secara konsisten dari hasil deteksi enam jenis risiko, sehingga informasi risiko yang ditampilkan kepada bidan menjadi lebih konsisten.
3. Model Random Forest Overall mencapai akurasi sebesar 95,55%, melampaui target akurasi minimal sebesar 80% yang telah ditetapkan.
4. *Risk_Score* (agregasi indikator risiko klinis) dan Riwayat Penyakit Berat merupakan fitur yang paling berpengaruh terhadap prediksi risiko keseluruhan.
5. Risiko BBLR/Stunting Bayi memperoleh nilai F1-Score tertinggi, yaitu sebesar 0,983, sedangkan Risiko Kematian Ibu memperoleh nilai F1-Score terendah, yaitu sebesar 0,739.

Perbedaan tersebut dipengaruhi oleh proporsi data positif Risiko Kematian Ibu yang lebih kecil, yaitu sebesar 10,2%.

6. *Feature engineering* berbasis kaidah klinis yang terdiri atas 41 fitur, termasuk MAP, flag anemia, KEK, dan hipertensi, serta mengacu pada panduan Kemenkes RI, WHO, POGI, ISSHP, dan Permenkes, berkontribusi dalam meningkatkan kualitas serta akuntabilitas klinis dari prediksi yang dihasilkan.

Dengan demikian, penerapan Machine Learning pada aplikasi Generasi Sehat diharapkan dapat mendukung terciptanya sistem monitoring kesehatan ibu dan anak yang lebih cerdas, terintegrasi, berbasis data, dan dapat dipertanggungjawabkan secara klinis, sehingga dapat mendukung peningkatan kualitas pelayanan kesehatan ibu dan anak di desa.